

1 Contexto y objetivo

Este proyecto desarrolla un proceso completo de Minería de Datos sobre un conjunto de usuarios de una plataforma de streaming, siguiendo una metodología reproducible y documentada en cada etapa, desde la inspección inicial hasta la interpretación de resultados. El objetivo fue comprender la calidad de los datos, justificar cada decisión de preparación y obtener evidencia para responder preguntas concretas sobre el comportamiento de los usuarios: identificar patrones de consumo, estudiar relaciones entre variables y evaluar el aporte del Análisis de Componentes Principales (PCA) como técnica de reducción de dimensionalidad. En todo momento se priorizó la **trazabilidad**: cada transformación se respaldó en evidencia obtenida durante la inspección y el análisis exploratorio.

2 Dataset y calidad inicial

El dataset reúne información de usuarios de streaming en cuatro grupos de variables: **demográficas**, **características de la suscripción**, **hábitos de consumo** y **métricas de interacción** con el servicio. La inspección inicial mostró una calidad general adecuada, con problemas acotados y asociados principalmente a errores de carga y diferencias de formato: registros duplicados, valores faltantes, inconsistencias en variables categóricas, formatos de fecha heterogéneos y valores numéricos fuera de rangos plausibles.

3 Decisiones de limpieza y preparación

Se aplicaron **únicamente** transformaciones justificadas por la evidencia, preservando la mayor cantidad posible de información original:

Problema detectado	Decisión adoptada	Justificación
Duplicados completos	Eliminación de filas idénticas	Un mismo ID con datos distintos son observaciones reales, por lo que se conservan.
Variables categóricas	Normalización (mayús./minús. y espacios)	Unifica la escritura sin alterar el significado de la información.
Numéricos imposibles	Conversión a faltante e imputación por mediana	La mediana es robusta frente a valores extremos.
monthly_watch_time_mins	Imputación por mediana según plan	La variable se comporta distinto según el tipo de suscripción.
Fechas inválidas	Se conservan como ausentes (NaT)	No se infieren fechas ficticias; se preserva la integridad del dato.

Todas las transformaciones quedaron registradas en el **log ETL**, garantizando la reproducibilidad y la comparación entre el estado inicial y final del conjunto de datos.

4 Hallazgos del análisis exploratorio

El análisis exploratorio respondió las preguntas planteadas y validó las decisiones de preparación:

Eje analizado	Hallazgo principal
Tiempo de visualización	Distribución asimétrica a la derecha: la mayoría consume de forma moderada y un grupo reducido concentra tiempos muy altos (usuarios altamente activos).
subscription_plan	Relación más clara del estudio: los planes Premium registran mayor tiempo promedio que Standard y Basic, pese a cierta superposición entre distribuciones.
Edad vs. tiempo	Sin asociación lineal significativa; la edad por sí sola no explica los hábitos de consumo.
Correlaciones numéricas	Débiles entre sí: el comportamiento responde a múltiples factores, no a una sola variable.

En conjunto, ninguna variable individual explica el comportamiento observado, lo que motivó avanzar hacia la reducción de dimensionalidad mediante PCA.

5 Análisis de Componentes Principales (PCA)

Se aplicó PCA sobre las variables numéricas, previa estandarización con `StandardScaler` para que todas participaran en igualdad de condiciones, independientemente de su unidad o magnitud. Las primeras componentes concentraron una parte importante de la varianza, resumiendo la estructura del dataset mediante nuevas variables no correlacionadas. El estudio de las cargas factoriales mostró que ninguna variable explica por sí sola el comportamiento: las componentes son combinaciones de las originales, en línea con las correlaciones débiles del análisis exploratorio. Así, el PCA no solo redujo la dimensionalidad, sino que confirmó la naturaleza **multifactorial** del comportamiento de los usuarios.

6 Conclusiones y limitaciones

El proyecto construyó un proceso completo y **reproducible** de Minería de Datos, manteniendo la trazabilidad de cada decisión. La preparación mejoró la calidad del dataset sin modificaciones arbitrarias; el análisis exploratorio identificó diferencias de consumo según el tipo de suscripción y una influencia limitada de la edad; y el PCA confirmó que las variables aportan información de forma conjunta.

Limitaciones y trabajo futuro. El análisis es descriptivo y depende de las variables disponibles, por lo que las conclusiones no implican causalidad. Como líneas futuras se propone incorporar nuevas variables, realizar estudios temporales con información cronológica más completa y complementar el enfoque descriptivo con modelos predictivos para estimar el consumo o segmentar usuarios.

Repositorio GitHub	github.com/mateocantos/PI_Mineria_Datos_1
Aplicación Streamlit	_____